Steam News & SteamSpy Data Warehouse

Kurzbericht zum Data-Warehouse-Projekt

Studiengang: Digital Medizin – Medical Data Science
Modul: Data Warehouse in der Medizin
Semester: 1. Fachsemester
Name: Jannis Engemann
Abgabedatum: 16.02.2025

Inhaltsverzeichnis

1 Einleitung und Zielsetzung 2

2 Methodischer Rahmen 2

3 Systemarchitektur 3

4 Datenquellen 3

5 Datenmodell und ERM 4

6 ETL-Prozess 5

7 Technische Konsistenz und Qualitätssicherung 6

8 Datenqualität und Quellenlimitationen 6

9 Analytische Auswertungen 7

10 Diskussion und Limitationen 7

11 Fazit und Ausblick 8

1 Einleitung und Zielsetzung

Ziel des Projekts ist die konzeptionelle und technische Realisierung eines reproduzierbaren Data-Warehouse-Systems zur Integration heterogener Steam-Datenquellen. Im Mittelpunkt steht die Fragestellung, wie veröffentlichte Content-Aktivitäten auf Steam (Steam-News) mit plattformbezogenen Nutzermetriken wie Concurrent Users (CCU), geschätzten Besitzerzahlen (Intervallangaben) sowie positiven und negativen Nutzerbewertungen in einem konsistent historisierbaren Modell zusammengeführt werden können.

Der Schwerpunkt liegt nicht auf dem Nachweis kausaler Effekte, sondern auf einer technisch sauberen Integration und Modellierung der Daten sowie der explorativen Analyse potenzieller Zusammenhänge.

Die Umsetzung erfolgt als lokal ausführbarer Docker-Stack (PostgreSQL, Python-ETL, optionale BI-Schicht mit Apache Superset). Der Fokus liegt auf Reproduzierbarkeit, Transparenz und einer sauberen technischen Umsetzung.

2 Methodischer Rahmen

Architekturansatz: Das System folgt einem klassischen Data-Warehouse-Aufbau mit klarer Trennung zwischen Datenquellen, ETL-Schicht, persistenter DWH-Schicht und analytischer Zugriffsebene. Implementiert wurde ein Snowflake-Schema. Faktentabellen speichern Ereignis- bzw. Snapshotdaten, während Dimensionstabellen normalisierte Kontextinformationen enthalten. Diese Struktur ermöglicht konsistente Analysen bei kontrollierter Redundanz.

Historisierungskonzept: Zentrales Element ist eine run-basierte Historisierung. Jeder ETL-Lauf wird als eigenständige Instanz in der Dimension `dim_etl_run` erfasst. Snapshot-Metriken aus SteamSpy werden explizit zeitpunktbezogen interpretiert. Die Historisierung erfolgt nicht auf Ebene einzelner Attributänderungen, sondern über vollständige Snapshots pro ETL-Lauf. Jeder Run repräsentiert damit einen konsistenten Datenstand zu einem bestimmten Zeitpunkt.

Snapshot-Interpretation: Die SteamSpy-Daten stellen aggregierte Momentaufnahmen dar. Veränderungen zwischen zwei ETL-Runs ergeben sich aus dem Vergleich dieser Zeitpunkte und sind nicht als direkt beobachtete Ereignisse zu verstehen.

3 Systemarchitektur

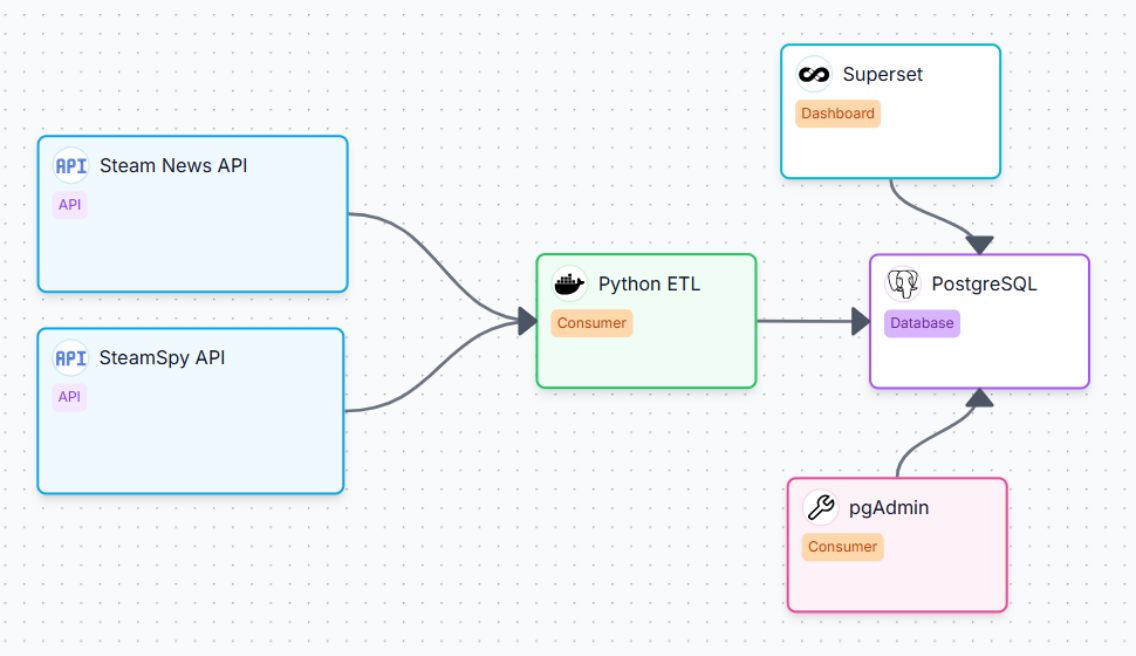

Abbildung 1: Systemarchitektur

Die Architektur (Abbildung 1) besteht aus folgenden Komponenten:

- Externe APIs (Steam News API, SteamSpy API)
- Python-basierter ETL-Prozess
- PostgreSQL Data Warehouse
- Optionale BI-Schicht (Apache Superset)
- Optionales Admin Tool (pgAdmin)

Die Infrastruktur ist vollständig containerisiert (Docker Compose). Konfiguration und Laufmodi (Initial Run, Incremental Run) werden über Environment-Variablen gesteuert. Dadurch wird ein reproduzierbares Setup mit klar definierten Zuständen ermöglicht.

4 Datenquellen

Steam News API: `https://api.steampowered.com/ISteamNews/GetNewsForApp/v2/?appid=730`

Geliefert werden News-Ereignisse mit Titel, URL, Zeitstempel sowie weiteren Metadaten. Die Daten liegen JSON-basiert und semi-strukturiert vor.

SteamSpy API: `https://steamspy.com/api.php?request=all`

Bereitgestellt werden Snapshot-Metriken wie Concurrent Users (CCU), abgeschätzte Spielzeit, Owner-Range, Positive/Negative Reviews und Preis- und Discount-Felder. Die Owner-Range

wird in numerische Minimal- und Maximalwerte transformiert, um Vergleichbarkeit sicherzustellen. Dennoch handelt es sich um approximative Kennzahlen, da SteamSpy auf externen Schätzverfahren basiert.

5 Datenmodell und ERM

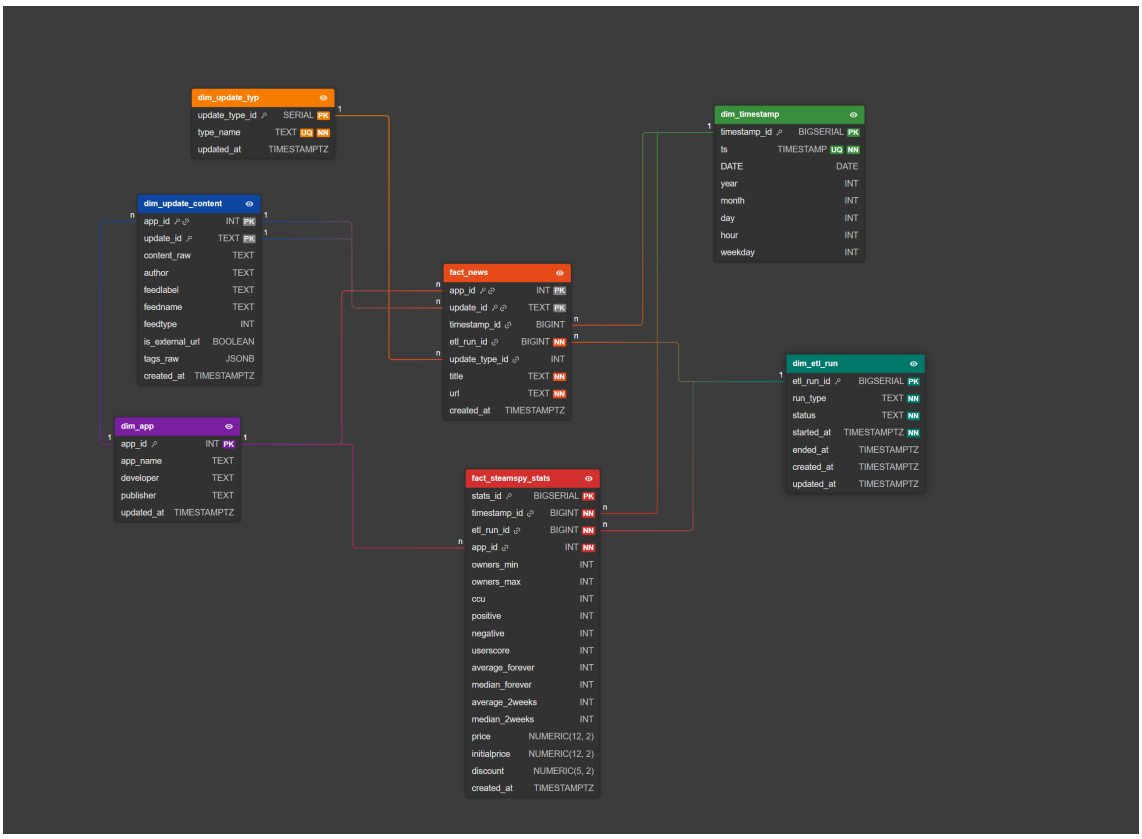

Abbildung 2: ERM

Das Schema (Abbildung 2) umfasst zwei zentrale Faktentabellen (`fact_news` und `fact_steamspy_stats`) sowie mehrere Dimensionstabellen (u. a. `dim_app`, `dim_timestamp`, `dim_update_type`, `dim_update_content`, `dim_etl_run`).

Eine zentrale Modellierungsentscheidung betrifft die fehlende globale Eindeutigkeit der von der Steam News API gelieferten `update_id` (in der API als `gid`). Diese ist nur innerhalb einer einzelnen Anwendung eindeutig. Im Data Warehouse wird die Identität daher über einen zusammengesetzten Schlüssel aus `app_id` und `update_id` sichergestellt.

Die referenzielle Integrität wird durch Primary- und Foreign-Keys sowie ergänzende NOT-NULL- und CHECK-Constraints abgesichert, sodass Faktentabellen ausschließlich auf gültige Dimensionseinträge verweisen können.

Zur Verifikation der Schema- und Befüllungsintegrität kann nach Initialisierung oder ETL-Ausführung ein Smoke-Test ausgeführt werden, der die Existenz zentraler Tabellen, Schlüsselattribute sowie das Fehlen verwaister Faktendatensätze (Orphan-Checks) überprüft.

6 ETL-Prozess

Der ETL-Prozess vereinheitlicht Daten aus der Steam News API und der SteamSpy API und persistiert diese in einem relationalen PostgreSQL-Data-Warehouse. Die Ausführung erfolgt containerisiert (Docker) oder lokal. Ziel ist eine reproduzierbare, nachvollziehbare und robuste Datenintegration.

Betriebsmodi: Der ETL unterstützt zwei Ausführungsvarianten:

- **Initial Run:** Vollständige Erstbefüllung des Schemas mit dem verfügbaren Datenbestand innerhalb definierter Limits.
- **Incremental Run:** Nachladen neuer News-Ereignisse sowie Erzeugung eines zusätzlichen SteamSpy-Snapshots seit dem letzten erfolgreichen Lauf.

Jeder Lauf wird in `dim_etl_run` erfasst und mit Metadaten (Startzeit, Status, Laufzeit) historisiert. Dadurch sind abgeschlossene Datenstände eindeutig referenzierbar.

SteamSpy-Phase: In der SteamSpy-Phase wird der Endpoint `request=all` abgerufen. Für jede Anwendung erfolgt ein Upsert der Stammdaten in `dim_app` sowie die Transformation der Owner-Range in numerische Minimal- und Maximalwerte (`owners_min`, `owners_max`). Anschließend wird ein Snapshot-Datensatz in `fact_steamspy_stats` erzeugt und eindeutig einem ETL-Run zugeordnet.

Eine zentrale Einschränkung besteht darin, dass SteamSpy Besitzerzahlen ausschließlich als Intervalle und weitere Kennzahlen als approximative Schätzwerte bereitstellt. Die Transformation verbessert die Vergleichbarkeit, ersetzt jedoch keine offiziell verifizierten Plattformdaten.

Steam-News-Phase: Die News-Phase verarbeitet alle in `dim_app` enthaltenen Anwendungen. Der Abruf erfolgt paginiert; im Incremental Run wird pro Anwendung ein Cutoff-Zeitpunkt bestimmt, um bereits verarbeitete Einträge auszuschließen.

Die fehlende globale Eindeutigkeit der `update_id` stellt dabei eine zentrale Modellierungsherausforderung dar. Da diese nur innerhalb einer Anwendung eindeutig ist, wird die Identität im Data Warehouse über den zusammengesetzten Schlüssel (`app_id`, `update_id`) sichergestellt.

Unvollständige oder inkonsistente Datensätze werden kontrolliert übersprungen, um die strukturelle Integrität des Schemas zu gewährleisten; Duplikate werden erkannt und nicht erneut geladen.

Robustheit und Fehlerbehandlung: Zur Sicherstellung einer stabilen Datenintegration implementiert der ETL transaktionale Fehlerisolierung sowie Wiederholungsmechanismen bei temporären API-Fehlern. Die Verarbeitung ist so ausgelegt, dass partielle Fehler nicht zum Abbruch des gesamten Laufs führen und jeder ETL-Run als konsistenter Datenstand nachvollziehbar bleibt.

7 Technische Konsistenz und Qualitätssicherung

Die referenzielle Integrität des Schemas wird durch Primary- und Foreign-Keys sowie ergänzende NOT-NULL- und CHECK-Constraints sichergestellt.

Zur Validierung der Schema- und Befüllungsintegrität kann ein Smoke-Test ausgeführt werden, der zentrale Tabellen, Schlüsselattribute und Fremdschlüsselbeziehungen (Orphan-Checks) prüft.

Durch die containerisierte Infrastruktur ist das System reproduzierbar ausführbar; Schema-Initialisierung, ETL-Läufe und abhängige Dienste können in identischer Umgebung wiederholt werden.

Zusätzlich wird die kontinuierliche Funktionsfähigkeit des Gesamtsystems durch einen GitHub-Workflow abgesichert. Dieser prüft bei Änderungen automatisiert, ob sich die Container starten lassen, das Schema korrekt aufgebaut werden kann, der ETL-Prozess lauffähig ist und das System in einem konsistenten und direkt ausführbaren Gesamtzustand verbleibt.

8 Datenqualität und Quellenlimitationen

Neben der technischen Integrität ist die inhaltliche Qualität der integrierten Daten zu berücksichtigen.

Steam News API: Die Steam News API liefert veröffentlichte Content-Einträge, deren Struktur maßgeblich von den jeweiligen Publishern abhängt. Felder wie Update-Typ oder Tags sind nicht verpflichtend und teilweise inkonsistent gepflegt. Leere oder uneinheitlich verwendete Klassifikationen sind daher möglich.

Der ETL-Prozess berücksichtigt diese Eigenschaften durch Typnormalisierung, kontrolliertes Überspringen unvollständiger Datensätze sowie separate Dimensionstabellen für Klassifikationen. Dennoch bleibt die semantische Qualität einzelner Felder von der Pflegepraxis der Publisher abhängig.

SteamSpy API: SteamSpy-Daten basieren auf Schätzverfahren und sind keine offiziell verifizierten Plattformdaten von Valve. Besitzerzahlen werden als Intervalle angegeben und stellen statistische Approximationen dar.

Die Kennzahl Concurrent Users (CCU) entspricht laut SteamSpy-Dokumentation dem am Vortag erreichten Peak-Wert gleichzeitig aktiver Nutzer einer Anwendung („peak CCU yesterday“). Es handelt sich somit nicht um einen aktuellen Momentwert, sondern um einen tagesbezogenen Maximalwert.

Im beobachteten Implementierungszeitraum blieben die von SteamSpy gelieferten CCU-Werte konstant. Run-basierte Differenzanalysen sind in dieser Kennzahl daher nur eingeschränkt aussagekräftig und verdeutlichen die Abhängigkeit analytischer Möglichkeiten von der Aktualisierungslogik externer Quellen.

Aktualisierungsfrequenz: Der ETL ist auf eine tägliche Ausführung ausgelegt. Preis- und Discount-Felder sowie weitere SteamSpy-Metriken werden bei jedem Run neu geladen und entsprechen dem zum jeweiligen Abrufzeitpunkt bereitgestellten Datenstand. SteamSpy aktualisiert seine Daten ebenfalls typischerweise einmal täglich; kurzfristige Schwankungen innerhalb eines Tages werden dadurch nicht abgebildet.

Insgesamt ist die technische Datenkonsistenz hoch, während zeitliche Auflösung und inhaltliche Validität einzelner Kennzahlen durch die Eigenschaften der externen Quellen begrenzt bleiben.

9 Analytische Auswertungen

Für die Auswertung wurden auf Basis des DWH-Schemas konsolidierte Abfragen erstellt, die pro ETL-Run und Anwendung einen eindeutig definierten Datenstand liefern. Ziel war es, komplexe Join-Logik und Zeitbezüge aus der Visualisierungsebene herauszulösen und konsistente Vergleichsgrundlagen zu schaffen.

Run-basierter Snapshot: Für jeden ETL-Lauf wird pro Anwendung ein konsistenter Zustand zentraler Kennzahlen bereitgestellt. Dazu zählen u. a. CCU (Peak vom Vortag), Besitzerintervalle, Nutzerbewertungen sowie Preis- und Discount-Informationen. Jeder Run repräsentiert damit einen klar abgrenzbaren Datenstand.

Zeitliche News-Aggregation: Die Anzahl veröffentlichter News wird relativ zum jeweiligen ETL-Zeitpunkt über 7- und 30-Tage-Fenster aggregiert. Dadurch lassen sich News-Aktivität und Plattformmetriken innerhalb desselben Zeitbezugs vergleichen.

Veränderungen zwischen ETL-Runs: Für ausgewählte Kennzahlen werden Differenzen zum jeweils vorherigen Run berechnet. Auf diese Weise werden strukturelle Änderungen zwischen zwei konsistenten Datenständen sichtbar (z. B. Preisänderungen, Discount-Anpassungen oder Veränderungen in Bewertungskennzahlen).

Darauf aufbauend wurden mehrere Dashboard-Sichten umgesetzt: ein Gesamtüberblick des aktuellen Datenstands, eine Detailansicht einzelner Anwendungen mit Verlauf über mehrere Runs, der Vergleich aufeinanderfolgender ETL-Läufe sowie eine explorative Betrachtung des Zusammenhangs zwischen News-Aktivität und Nutzerkennzahlen.

Die Auswertungen sind deskriptiv und explorativ angelegt. Beobachtete Muster werden als potenzielle Zusammenhänge interpretiert und nicht als Nachweis kausaler Effekte verstanden.

10 Diskussion und Limitationen

Die Aussagekraft der Analysen ist maßgeblich durch die Eigenschaften der verwendeten Datenquellen bestimmt. Insbesondere die SteamSpy-Daten basieren auf öffentlich zugänglichen Schätzverfahren und stellen keine offiziell verifizierten Plattformdaten dar. Besitzerzahlen

werden als Intervalle angegeben, und die CCU-Kennzahl bildet den am Vortag erreichten Peak-Wert ab. Die inhaltliche Validität dieser Kennzahlen ist daher begrenzt und als approximativ zu verstehen.

Auch die historische Tiefe des betrachteten Zeitraums ist noch eingeschränkt. Run-basierte Vergleiche ermöglichen konsistente Gegenüberstellungen mehrerer Datenstände, ersetzen jedoch keine langfristige Zeitreihenanalyse mit hoher zeitlicher Auflösung.

Die gewählte Append-only-Strategie erhöht die Nachvollziehbarkeit und Revisionssicherheit der Datenhaltung, erschwert jedoch nachträgliche Korrekturen historischer Datensätze. Fehlerhafte oder inkonsistente Quelldaten würden ebenfalls historisiert bleiben.

Gleichzeitig zeigt die Umsetzung mehrere Stärken: Die klare Trennung zwischen Datenquellen, ETL-Logik, Persistenzschicht und analytischer Auswertung ermöglicht eine transparente und nachvollziehbare Architektur. Die run-basierte Historisierung schafft eindeutig definierte Vergleichszeitpunkte und verhindert Mehrdeutigkeiten bei Aggregationen. Die semantische Heterogenität der Steam-News-Daten wird durch strukturierte Dimensionstabellen und Transformationslogik methodisch abgefedert.

11 Fazit und Ausblick

Im Rahmen des Projekts wurde ein reproduzierbarer, containerisierter Data-Warehouse-Stack implementiert, der heterogene Steam-Datenquellen konsistent integriert und run-basiert historisiert. Der Schwerpunkt lag auf einer sauberen Modellierung, robustem ETL-Design sowie einer klar strukturierten analytischen Auswertung.

Besonders hervorzuheben sind die konsistente Run-Logik sowie die methodisch saubere Zeitankerung der News-Aggregationen. Dadurch entsteht eine stabile Grundlage für explorative Analysen und vergleichbare Datenstände.

Gleichzeitig ist die Aussagekraft einzelner Kennzahlen durch die Eigenschaften der externen Datenquellen begrenzt. Die Umsetzung versteht sich daher nicht als statistisches Bewertungsinstrument, sondern als technisch saubere Referenzarchitektur zur strukturierten Integration und Analyse externer Plattformdaten.

Mögliche Weiterentwicklungen umfassen:

- Integration zusätzlicher oder offiziell verifizierter Datenquellen,
- Verlängerung des Beobachtungszeitraums zur Erhöhung der historischen Tiefe,
- feinere zeitliche Granularität der Datenerhebung,
- Erweiterung um formalisierte Data-Quality-Kennzahlen,
- Ausbau in Richtung produktionsnahes Monitoring und automatisierte Fehlerdiagnostik.

Insgesamt demonstriert das Projekt eine technisch konsistente, reproduzierbare und methodisch reflektierte Umsetzung eines run-basierten Data-Warehouse-Ansatzes zur strukturierten Integration und Analyse externer Plattformdaten.